

PREDIÇÃO DE GÊNERO EM REVIEWS

Gabriel Cortez

Dataset Utilizado

- **B2W-Reviews01**
- **Aproximadamente 128 mil reviews**
- **Reviews em português**
- **Dados reais de e-commerce**



Tipo de Problema

- **Classificação binária**
- **Classes:**
- **$M \rightarrow$ Masculino**
- **$F \rightarrow$ Feminino**



Desafio Principal

Evitar que o modelo aprenda apenas:

- **categorias de produtos**
- **relações sociais explícitas**
- **palavras enviesadas**
-

Objetivo: focar mais no estilo de escrita do autor.



MODELO

Pré-processamento

- Remoção de URLs
- Remoção de HTML
- Normalização de números
- Limpeza textual leve
- Remoção de palavras de categoria
- Remoção de relações sociais explícitas

- Justificativas:

- Remover ruído (URLs/HTML) melhora sinais textuais.
- TF-IDF captura importância de termos em corpus grande.
- char n-grams ajudam morfologia/terminações relacionadas a gênero.

Abordagem

Pré-processamento

- Remoção de URLs
- Remoção de HTML
- Normalização de números
- Limpeza textual leve
- Remoção de palavras de categoria
- Remoção de relações sociais explícitas

Representação Textual

Utilização de:

- TF-IDF Word N-Grams
- TF-IDF Character N-Grams
- Features estilométricas

Justificativas

Por que TF-IDF?

- Excelente desempenho em NLP clássico
- Leve e eficiente
- Boa interpretabilidade
- Funciona muito bem com textos curtos

Por que Character N-Grams?

- Captura padrões de escrita
- Reduz dependência semântica
- Mais robusto a erros ortográficos

Por que remover palavras específicas?

R: Reduzir leakage do modelo.

```
"shampoo",  
"condicionador",  
"hidratante",  
"perfume",  
"cabelo",  
"cabelos",  
"maquiagem",  
"serum",  
"máscara",  
"mascara",  
"escova",
```

```
"monitor",  
"fps",  
"gpu",  
"processador",  
"ssd",  
"placa",  
"renderizacao",  
"renderização",  
"notebook",  
"pc",  
"roteador",  
"televisor",  
"equipamento",
```

```
"jogo",  
"jogos",  
"game",  
"games",  
"steam",
```

```
"esposa",  
"esposo",  
"marido",  
"namorada",  
"namorado",  
"mulher",  
"noiva",  
"noivo",  
"amiga",  
"amigo",  
"mãe",  
"mae",  
"pai",  
"filha",  
"filho",
```


Features Utilizadas

TF-IDF Word Features

- Unigrams e Bigrams
- Captura contexto textual

TF-IDF Character Features

- N-grams de caracteres (4 a 6)
- Captura padrões estilísticos

Features Estilométricas

Exemplos:

- exclamações
- uso de maiúsculas
- palavras alongadas
- intensidade emocional
- primeira pessoa

Dimensionalidade

O modelo final possui:

- dezenas de milhares de features textuais
- alta dimensionalidade esparsa
- combinação entre semântica e estilo textual

Vantagens:

- Excelente desempenho em NLP
- Muito eficiente com TF-IDF
- Modelo leve e rápido
- Fácil serialização com pickle
- Boa generalização

Modelo

Logistic Regression + Calibração

Utilizado junto com:

- TF-IDF
- Features estilométricas
- Pipeline do sklearn

Vantagens

- Excelente desempenho em NLP
- Muito eficiente com TF-IDF
- Modelo leve e rápido
- Fácil serialização com pickle
- Boa generalização

Modelo

Alternativas Consideradas

- SVM

Motivo de não utilizar SVM no final:

A versão final precisava:

- compatibilidade direta com pickle
- pipeline pura do sklearn
- maior estabilidade de serialização

MODELO - ANTES

MULHER

```
WORD_satisfeita (-6.6320)
WORD_amei (-5.2999)
WORD_obrigada (-4.9422)
WORD_decepcionada (-4.5575)
WORD_insatisfeita (-3.2694)
WORD_adorei (-2.9346)
WORD_lindo (-2.7293)
WORD_satisfeita com (-2.6187)
WORD_muito satisfeita (-2.4672)
WORD_super (-2.3986)
CHAR_ada (-2.3216)
CHAR_onada (-2.2757)
CHAR_feita (-2.1624)
WORD_estou satisfeita (-2.1537)
CHAR_amei (-2.1301)
WORD_achei (-1.9218)
CHAR_eita (-1.9190)
CHAR_igada (-1.8817)
CHAR_lind (-1.8195)
WORD_super recomendo (-1.8124)
WORD_chateada (-1.8069)
WORD_cabelo (-1.7972)
WORD_marido (-1.7824)
CHAR_a! (-1.7681)
```

HOMEM

```
WORD_satisfeito (7.0086)
WORD_obrigado (4.3315)
WORD_decepcionado (3.8177)
WORD_esposa (3.4384)
WORD_minha esposa (3.2607)
WORD_muito satisfeito (2.7479)
WORD_insatisfeito (2.6357)
WORD_estou satisfeito (2.5812)
WORD_top (2.3774)
CHAR_nado (2.0528)
WORD_barba (1.9970)
WORD_atendido (1.8473)
CHAR_feito (1.7257)
CHAR_igado (1.6801)
WORD_satisfeito com (1.6710)
WORD_grato (1.6331)
WORD_no produto (1.5667)
CHAR_onado (1.5119)
WORD_enganado (1.5040)
WORD_não entrega (1.4947)
WORD_minha mulher (1.4893)
WORD_recomendo todos (1.4688)
CHAR_nado (1.4268)
WORD_eu mesmo (1.4210)
CHAR_posa (1.4009)
```

MODELO - ANTES

Texto: Produto excelente, adorei demais!!!

Predicao: F

Confianca: 0.8836

Texto: Monitor muito bom para jogos competitivos.

Predicao: M

Confianca: 0.9330

Texto: Achei o shampoo maravilhoso no meu cabelo.

Predicao: F

Confianca: 0.9962

Texto: Excelente desempenho em fps e renderizacao.

Predicao: M

Confianca: 0.6996

Texto: Minha esposa adorou o produto.

Predicao: M

Confianca: 0.9949

Texto: Estou muito satisfeito com a compra.

Predicao: M

Confianca: 0.9904

MODELO - ANTES

```
"shampoo",  
"condicionador",  
"hidratante",  
"perfume",  
"cabelo",  
"cabelos",  
"maquiagem",  
"serum",  
"máscara",  
"mascara",  
"escova",  
  
"monitor",  
"fps",  
"gpu",  
"processador",  
"ssd",  
"placa",  
"renderizacao",  
"renderização",  
"notebook",  
"pc",  
"roteador",  
"televisor",  
"equipamento",  
  
"jogo",  
"jogos",  
"game",  
"games",  
"steam",
```

```
RELATIONSHIP_WORDS = {  
  
    "esposa",  
    "esposo",  
    "marido",  
    "namorada",  
    "namorado",  
    "mulher",  
    "noiva",  
    "noivo",  
    "amiga",  
    "amigo",  
    "mãe",  
    "mae",  
    "pai",  
    "filha",  
    "filho",  
  
}
```

MODELO - DEPOIS

EXEMPLOS

Texto: Produto excelente, adorei demais!!!

Predicao: F

Confianca: 0.8703

Texto: Monitor muito bom para jogos competitivos.

Predicao: M

Confianca: 0.6087

Texto: Achei o shampoo maravilhoso no meu cabelo.

Predicao: F

Confianca: 0.9146

Texto: Excelente desempenho em fps e renderizacao.

Predicao: M

Confianca: 0.7646

Texto: Minha esposa adorou o produto.

Predicao: M

Confianca: 0.6745

Texto: Estou muito satisfeito com a compra.

Predicao: M

Confianca: 0.9768

TOP MASCULINAS

CHAR_sfeito (3.8968)

WORD_satisfeito (3.4192)

WORD_obrigado (1.8465)

CHAR_rigado (1.7784)

CHAR_nado (1.6896)

CHAR_igado (1.6642)

WORD_decepcionado (1.6541)

CHAR_feito (1.5268)

WORD_muito satisfeito (1.4933)

CHAR_onado (1.3277)

CHAR_top (1.2791)

WORD_estou satisfeito (1.2542)

WORD_top (1.2525)

CHAR_ionado (1.2178)

CHAR_gado (1.0952)

CHAR_nado (1.0352)

CHAR_eito (1.0175)

CHAR_feita (0.9660)

WORD_insatisfeito (0.9075)

CHAR_endido (0.8572)

CHAR_ndido (0.8500)

CHAR_ado (0.8460)

CHAR_meu p (0.8312)

WORD_satisfeito com (0.8276)

CHAR_ito, p (0.8133)

TOP FEMININAS

CHAR_sfeita (-3.9575)

WORD_satisfeita (-3.1697)

WORD_amei (-2.5661)

CHAR_amei (-2.4087)

WORD_obrigada (-2.0189)

CHAR_rigada (-2.0010)

CHAR_feita (-1.8954)

CHAR_igada (-1.8817)

CHAR_onada (-1.8741)

CHAR_ionada (-1.7997)

WORD_decepcionada (-1.7490)

CHAR_eita (-1.6488)

CHAR_lind (-1.6468)

CHAR_amei (-1.4769)

CHAR_gada (-1.4673)

WORD_muito satisfeita (-1.3769)

CHAR_nada (-1.3765)

WORD_estou satisfeita (-1.1709)

CHAR_amei (-1.1353)

CHAR_ada! (-1.1276)

WORD_satisfeita com (-1.1099)

CHAR_lindo (-1.1093)

WORD_insatisfeita (-1.0946)

CHAR_dorei (-1.0756)

MODELO COMPARATIVO

ANTES

Relatorio:

	precision	recall	f1-score	support
F	0.7037	0.6382	0.6693	12414
M	0.6878	0.7479	0.7166	13233
accuracy			0.6948	25647
macro avg	0.6957	0.6930	0.6930	25647
weighted avg	0.6955	0.6948	0.6937	25647

DEPOIS

Relatorio:

	precision	recall	f1-score	support
F	0.6915	0.6299	0.6592	12414
M	0.6796	0.7364	0.7069	13233
accuracy			0.6848	25647
macro avg	0.6855	0.6831	0.6830	25647
weighted avg	0.6854	0.6848	0.6838	25647

Fold 1: 0.6849
Fold 2: 0.6837
Fold 3: 0.6846
Fold 4: 0.6878
Fold 5: 0.6858

Media CV: 0.6854
Std CV: 0.0014

Validando...

Análise & Limitações

Principais Desafios:

- Reviews muito curtos
- Linguagem informal
- Erros ortográficos
- Possível desbalanceamento textual
-

Limitações:

- Ainda existe dependência parcial do conteúdo textual
- Não utiliza embeddings modernos
- Grande quantidade de features
- Possível viés de linguagem e consumo

